

# BIOMETRÍA II

## CLASE 5

### MODELOS CON MÁS DE UNA PREDICTORA

Adriana Pérez

Depto de Ecología, Genética y Evolución  
FECN, UBA


# Recuperación de suelos empetrolados de Comodoro Rivadavia

Luque, JL - Estación Experimental Chubut del INTA Trelew - 2009

2

- La **fitorremediación** es una técnica que emplea vegetales en combinación con microorganismos asociados a la rizósfera para remover, degradar o inmovilizar contaminantes contenidos en suelos, sedimentos y aguas
- Se desea estudiar el desempeño de dos especies vegetales perennes: charcao (*Senecio filaginoides*), nativa, y agropiro alargado (*Thynopiron ponticum*), exótica, para fitorremediar suelos empetrolados de Comodoro Rivadavia.
- La **bioestimulación** es la adición de nutrientes al suelo para estimular la actividad de microorganismos degradadores del contaminante. Se desea estudiar el efecto de la adición al suelo de un fertilizante (fósforo + nitrógeno).

¿Podemos, en un mismo ensayo, estudiar la efectividad de las plantas y la de los microorganismos en remover los HC del suelo?





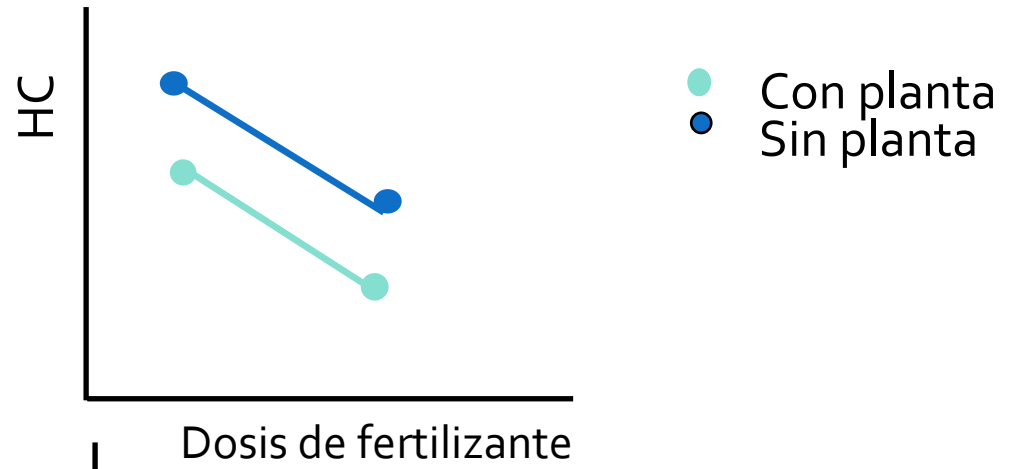

# Recuperación de suelos empetrolados de C. Rivadavia

Luque, JL - Estación Experimental Chubut del INTA Trelew - 2009



3

- Se planea un ensayo utilizando macetas conteniendo suelo extraído de la zona petrolera de Cdoro Rivadavia conteniendo 4.1% de hidrocarburos (HC) (4,1 g/100 g suelo seco)
- Se desea contestar las siguientes preguntas:
  - ¿Las especies son efectivas en remover los HC? (independientemente del agregado de fertilizante)
  - ¿Cuánto de la remoción de HC es por microorganismos del suelo y no por acción de las plantas?
  - ¿La fertilización es efectiva en promover la remoción de los HC? (independientemente del agregado de plantas)
  - La capacidad de remoción de HC de las especies ¿cambia según el agregado de fertilizante?



- ✓ Efectos nulos
- ✓ Efectos aditivos
- ✓ Interacción

# Interacción entre variables explicatorias

5

- El efecto de una VE sobre la VR cambia según los valores que tome otra VP
- Es decir que el efecto de una VE **depende de / se asocia con** el valor que tome otra VE (y viceversa) (**modificación de efectos**)
- Si hay interacción entre VE, pierde relevancia estimar los efectos de una dada VE independientemente de los valores que tome la otra VE con la que interactúa (**principio de marginalidad**)
- Las interacciones pueden ser entre cualquier tipo de variables (categóricas con categóricas, cuantitativas con categóricas, cuanti con cuanti...)

# Recuperación de suelos empetrolados de C. Rivadavia

Luque, JL - Estación Experimental Chubut del INTA Trelew - 2009



6

- 30 Macetas conteniendo suelo extraído de la zona petrolera de Cdro Rivadavia conteniendo 4.1% de hidrocarburos (HC) (4,1 g/100 g suelo seco)
- Cada maceta fue asignada al azar a una combinación de Planta (Charcao, Agropiro o Testigo sin vegetación) y Fertilización (con o sin)
- A los 350 días se midió contenido en suelo de HC totales de petróleo (% P/P, g/100 g suelo seco)
  
- Experimento o estudio observacional?
- UE:
- VR (tipo y potencial distribución de probabilidades):
- VE (tipo):
- Factores y niveles:
- Tratamientos:
- Diseño factorial de 3x2
- Replicación, aleatorización, control del error

# Diseños factoriales

7

- Son aquellos que incluyen más de una VE categórica (factor). Modelos de comparación de medias
- Mayor eficiencia en el uso de los recursos, menor error global y mayor potencia que varios unifactoriales
  - Permiten evaluar la **interacción** entre factores
  - Los **gráficos de perfiles** son muy útiles para describir el comportamiento de la VR
  - Cuando un experimento tiene dos o más factores, la cantidad de medias que pueden compararse surge de las combinaciones de los niveles de los factores

# El modelo es

$$Y \sim A * B$$

8

$$Y_{ijk} = \mu + \alpha_i + \beta_j + \alpha\beta_{ij} + \varepsilon_{ijk}$$

$$\begin{aligned} i &= 1, 2 \dots a \\ j &= 1, 2 \dots b \\ k &= 1, 2 \dots n_{ij} \end{aligned}$$

- donde  $Y_{ijk}$  es la concentración de HC en suelo de cada UE
- $\mu$  es la media general o media de la población
- $\alpha_i$  es el efecto del factor  $i$  (especie)
- $\beta_j$  es el efecto del factor  $j$  (fertilización)
- $\alpha\beta_{ij}$  es el efecto de la interacción  $ij$
- $\varepsilon_{ijk}$  es el error aleatorio de cada UE

$$\varepsilon_{ijk} \sim \text{NID}(0, \sigma^2)$$

tienen que ser cualis

En R: `m1 <- lm(HC ~ veg * fert, bd)`



# Hipótesis en Diseño factorial

9

□  $H_0: \gamma_{ij} = 0$

es decir no existe interacción entre especies y fertilización  $\Rightarrow$  El efecto de la fertilización es independiente de la especie (y viceversa)

Es la que debe analizarse primero, ya que si existe interacción no hay independencia entre los efectos de A y B y no es correcto analizar los factores por separado

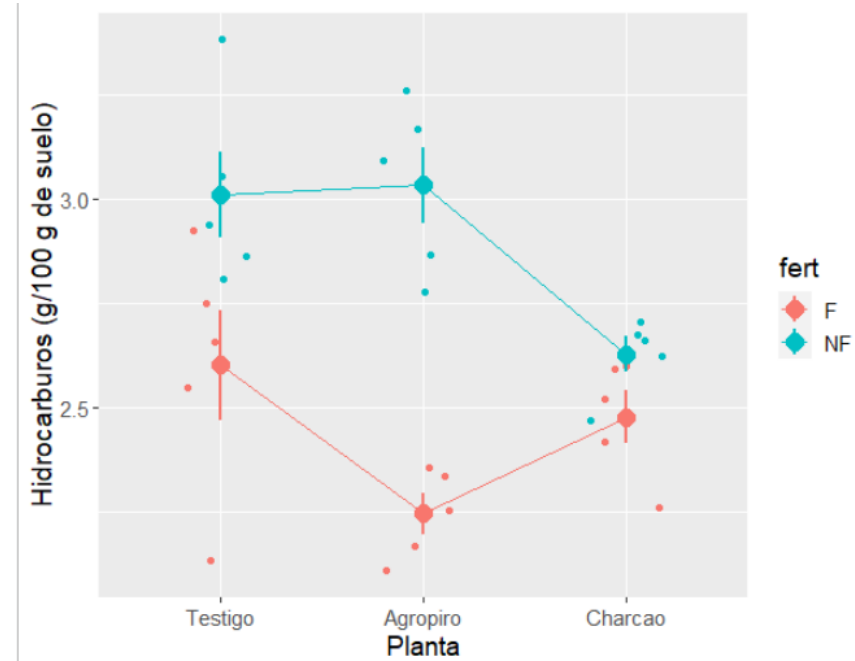
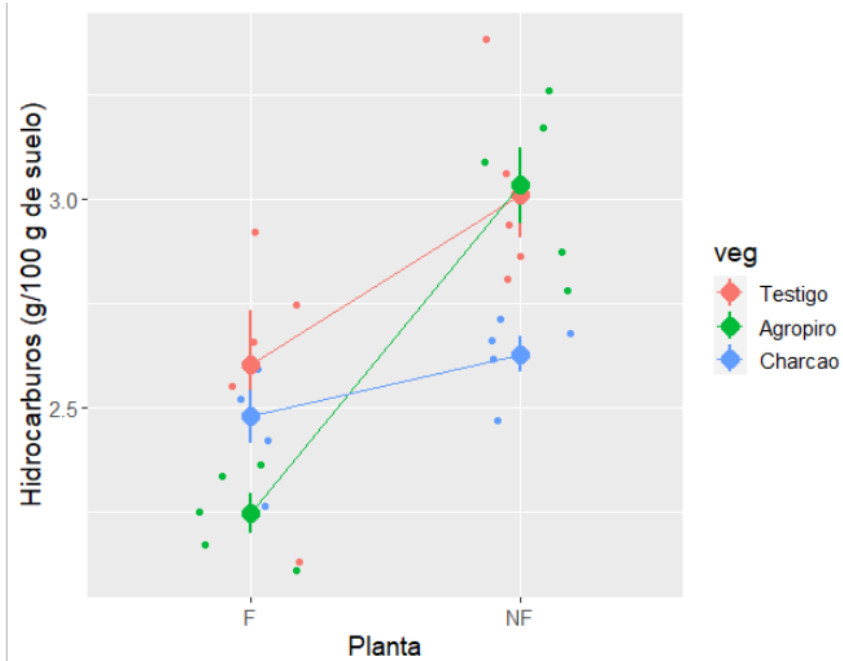
□  $H_0: \alpha_i = 0$

es decir no existe efecto sobre el contenido de HC del suelo debido a la especie (suponiendo independencia entre A y B)

□  $H_0: \beta_j = 0$

es decir no existe efecto sobre el contenido de HC del suelo debido a la fertilización (suponiendo independencia entre A y B)

# Gráficos de perfiles



Se pueden reordenar los niveles



```
factor(bd$veg, levels=c("Testigo", "Agro  
piro", "Charcao"))
```

# Calculando residuos



11

	Especie	Fertil	HC	Predichos	Residuos	residuos std
1	3	2	3.06	3.010	0.050	0.291
2	3	2	2.86	3.010	-0.150	-0.874
3	3	2	2.81	3.010	-0.200	-1.165
4	3	2	2.94	3.010	-0.070	-0.408
5	3	2	3.38	3.010	0.370	2.155
6	3	1	2.66	2.602	0.058	0.338
7	3	1	2.75	2.602	0.148	0.862
8	3	1	2.55	2.602	-0.052	-0.303
9	3	1	2.92	2.602	0.318	1.852
10	3	1	2.13	2.602	-0.472	-2.749
11	2	2	2.66	2.628	0.032	0.186
12	2	2	2.71	2.628	0.082	0.478
13	2	2	2.62	2.628	-0.008	-0.047
14	2	2	2.68	2.628	0.052	0.303
15	2	2	2.47	2.628	-0.158	-0.920
16	2	1	2.59	2.478	0.112	0.652
17	2	1	2.42	2.478	-0.058	-0.338
18	2	1	2.60	2.478	0.122	0.711
19	2	1	2.52	2.478	0.042	0.245
20	2	1	2.26	2.478	-0.218	-1.270

$$e_{ijk} = y_{ijk} - \bar{y}_{ij}$$

# Estudiando los supuestos

12



```
> leveneTest(HC~veg*fert, FITOR, center=mean)
```

Levene's Test for Homogeneity of Variance (center = mean)

	Df	F value	Pr(>F)
group	5	1.4057	0.2578
	24		

```
> shapiro.test(e)
```

Shapiro-Wilk normality test

data: e  
W = 0.97461, p-value = 0.6713



# Tabla de ANOVA

13

FdV	SC	GL	CM	F
Entre niveles factor A	$\sum b n_{ij} ( \bar{y}_{i.} - \bar{\bar{y}} )^2$	$a-1$	$\frac{SC_A}{Gl_A}$	$\frac{CM_A}{CM_{error}}$
Entre niveles factor B	$\sum a n_{ij} ( \bar{y}_{.j} - \bar{\bar{y}} )^2$	$b-1$	$\frac{SC_B}{Gl_B}$	$\frac{CM_B}{CM_{error}}$
AxB (interacción)	$\sum n_{ij} ( \bar{y}_{ij} - \bar{y}_{i.} - \bar{y}_{.j} + \bar{\bar{y}} )^2$	$(a-1)$ $(b-1)$	$\frac{SC_{AB}}{Gl_{AB}}$	$\frac{CM_{AB}}{CM_{error}}$
Error o dentro	$\sum ( y_{ijk} - \bar{y}_{ij} )^2$	$n-ab$	$\frac{SC_{error}}{GL_{error}}$	
Total	$\sum ( y_{ijk} - \bar{\bar{y}} )^2$	$n-1$		

# Anova

```
m1<-lm(HC~veg*fert, bd)
anova(m1)
```

Analysis of Variance Table

Response: HC

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
veg	2	0.33045	0.16522	4.4833	0.022164	*
fert	1	1.50976	1.50976	40.9668	1.283e-06	***
veg:fert	2	0.51501	0.25750	6.9872	0.004061	**
Residuals	24	0.88448	0.03685			

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Pruebas globales

No es correcto analizar  
efectos principales

# Efectos principales y simples

15

**Efectos principales o marginales** de un factor son las comparaciones entre los niveles de un factor promediados para todos los niveles del otro factor. Es decir, *independientemente* del otro factor.

**Efectos simples o comparaciones de interacción (de celdas)** son comparaciones entre distintos niveles de un factor fijando los niveles del otro factor.

Medias HC	Especie			$\bar{y}_{.j}$
Fertilización	Testigo	Charcao	Agropiro	
no	3,01	2,63	3,03	<b>2,890</b>
sí	2,60	2,48	2,25	<b>2,443</b>
$\bar{y}_i$	<b>2,805</b>	<b>2,555</b>	<b>2,640</b>	<b>2,667</b>

Efectos simples  
(celdas; dentro de la tabla)

Efectos principales  
(marginales)

## Principio de Marginalidad

- No deben interpretarse los efectos principales de las VE que interactúan
- No deben plantearse modelos con términos de interacción sin incluir los efectos principales

# Comparaciones múltiples

16

- Los métodos disponibles y el procedimiento es el mismo que para anova de un factor
- Si la interacción fue no significativa se comparan los efectos principales y se efectúan comparaciones entre niveles de cada factor
- Si la interacción fue significativa no se comparan efectos principales, sino comparaciones entre celdas



# Comparaciones de interacción

(entre todas las combinaciones)

```
library(eemmeans)  
emmeans(m1, pairwise ~ fert*veg)
```

IC para la diferencia de medias:  
¿Cero pertenece al IC?  
¿Cuál es la magnitud del efecto?


Confidence level used: 0.95

\$contrasts

contrast	estimate	SE	df	t.ratio	p.value	lower.CL	upper.CL
NF,Testigo - F,Testigo	0.408	0.121	24	3.360	0.0277	0.0326	0.7834
NF,Testigo - NF,Agropiro	-0.024	0.121	24	-0.198	1.0000	-0.3994	0.3514
NF,Testigo - F,Agropiro	0.764	0.121	24	6.293	<.0001	0.3886	1.1394
NF,Testigo - NF,Charcao	0.382	0.121	24	3.146	0.0445	0.0066	0.7574
NF,Testigo - F,Charcao	0.532	0.121	24	4.382	0.0024	0.1566	0.9074
F,Testigo - NF,Agropiro	-0.432	0.121	24	-3.558	0.0176	-0.8074	-0.0566
F,Testigo - F,Agropiro	0.356	0.121	24	2.932	0.0701	-0.0194	0.7314
F,Testigo - NF,Charcao	-0.026	0.121	24	-0.214	0.9999	-0.4014	0.3494
F,Testigo - F,Charcao	0.124	0.121	24	1.021	0.9062	-0.2514	0.4994
NF,Agropiro - F,Agropiro	0.788	0.121	24	6.490	<.0001	0.4126	1.1634
NF,Agropiro - NF,Charcao	0.406	0.121	24	3.344	0.0287	0.0306	0.7814
NF,Agropiro - F,Charcao	0.556	0.121	24	4.579	0.0015	0.1806	0.9314
F,Agropiro - NF,Charcao	-0.382	0.121	24	-3.146	0.0445	-0.7574	-0.0066
F,Agropiro - F,Charcao	-0.232	0.121	24	-1.911	0.4200	-0.6074	0.1434
NF,Charcao - F,Charcao	0.150	0.121	24	1.235	0.8153	-0.2254	0.5254

P value adjustment: tukey method for comparing a family of 6 estimates

`emmeans(m1, pairwise ~ fert*veg)`



- Las barras grises son los IC para las medias
- las flechas rojas son para las comparaciones entre grupos. Si una flecha de un grupo se superpone a una flecha de otro grupo, la diferencia no es significativa
- Nota: Nunca usar IC para una media para realizar comparaciones, pueden ser muy engañosos

```
> CLD(comp1)
```

fert	veg	emmean	SE	df	lower.CL	upper.CL	.group
F	Agropiro	2.246	0.08585259	24	2.068809	2.423191	1
F	Charcao	2.478	0.08585259	24	2.300809	2.655191	12
F	Testigo	2.602	0.08585259	24	2.424809	2.779191	12
NF	Charcao	2.628	0.08585259	24	2.450809	2.805191	2
NF	Testigo	3.010	0.08585259	24	2.832809	3.187191	3
NF	Agropiro	3.034	0.08585259	24	2.856809	3.211191	3

Confidence level used: 0.95

P value adjustment: tukey method for comparing a family of 6 estimates

significance level used: alpha = 0.05

## 2- Otra posibilidad: efectos simples

```
emmeans(m1, ~ fert | veg)
```

```
$contrasts
```

```
veg = Agropiro:
```

contrast	estimate	SE	df	t.ratio	p.value
F - NF	-0.788	0.1214139	24	-6.490	<.0001


```
veg = Charcao:
```

contrast	estimate	SE	df	t.ratio	p.value
F - NF	-0.150	0.1214139	24	-1.235	0.2286

```
veg = Testigo:
```

contrast	estimate	SE	df	t.ratio	p.value
F - NF	-0.408	0.1214139	24	-3.360	0.0026

- Mayor potencia, ya que son menos comparaciones
- La elección depende de los objetivos del ensayo



- ✓ Para cada tipo de planta ¿es efectiva la fertilización?
- ✓ O podría interesar: Para cada nivel de fertilización ¿cuál es la especie más efectiva?

## 2- efectos simples en el otro sentido

```
emmeans(m1, ~ veg | fert)
```

\$contrasts


fert = F:

contrast	estimate	SE	df	t.ratio	p.value
Testigo - Agropiro	0.356	0.121	24	2.932	0.0192
Testigo - Charcao	0.124	0.121	24	1.021	0.5709
Agropiro - Charcao	-0.232	0.121	24	-1.911	0.1574


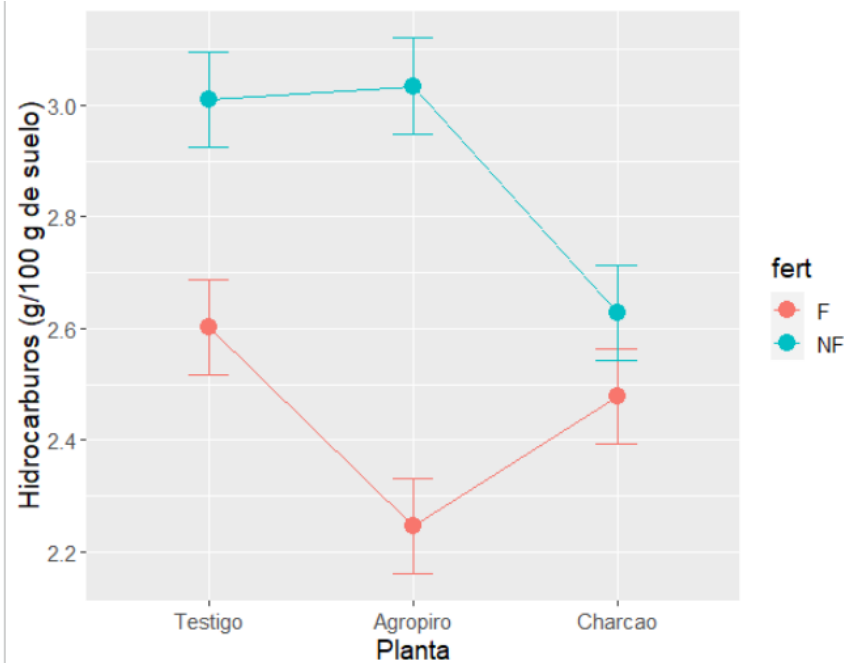
fert = NF:

contrast	estimate	SE	df	t.ratio	p.value
Testigo - Agropiro	-0.024	0.121	24	-0.198	0.9787
Testigo - Charcao	0.382	0.121	24	3.146	0.0117
Agropiro - Charcao	0.406	0.121	24	3.344	0.0073

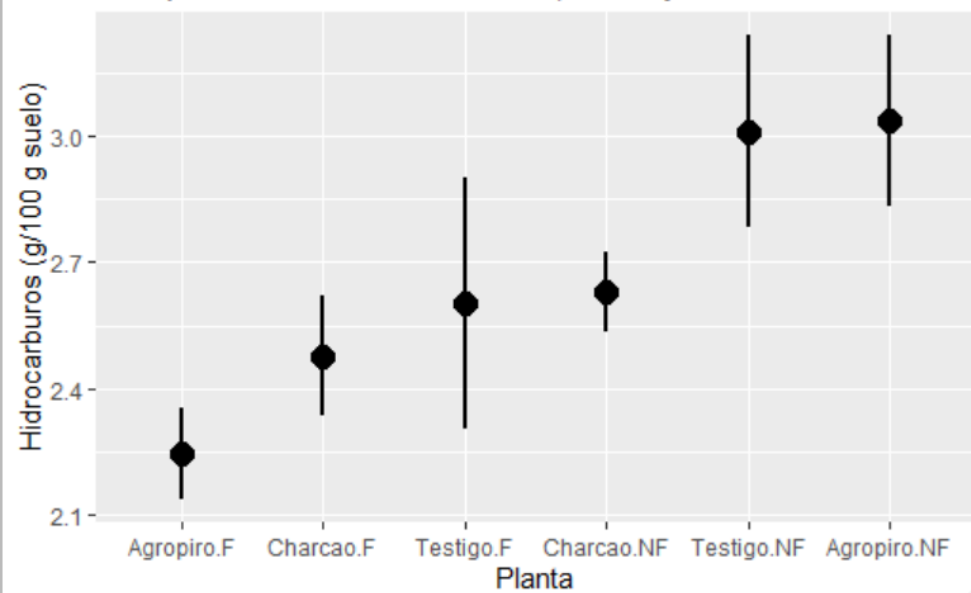
- Mayor potencia, ya que son menos comparaciones
- La elección depende de los objetivos del ensayo



- ✓ Para cada nivel de fertilización ¿cuál es la especie más efectiva?
- ✓ O uno u otro, pero no ambos



Comparación de tratamientos (media y DE)



¿Cuál es la pregunta a responder?

- ✓ Para cada nivel de vegetación ¿es efectiva la fertilización?
- ✓ Para cada nivel de fertilización ¿cuál es la especie más efectiva?
- ✓ ¿Cuál es el mejor de estos tratamientos para restaurar el suelo?
- ✓ ¿Cuál es la magnitud de los efectos?

```
> CLD(comp1)
fert veg .group
F Agropiro 1
F Charcao 12
F Testigo 12
NF Charcao 2
NF Testigo 3
NF Agropiro 3
```

# Test de Tukey

## si la interacción no es significativa

Efectos principales:

Comparaciones entre niveles del factor fert

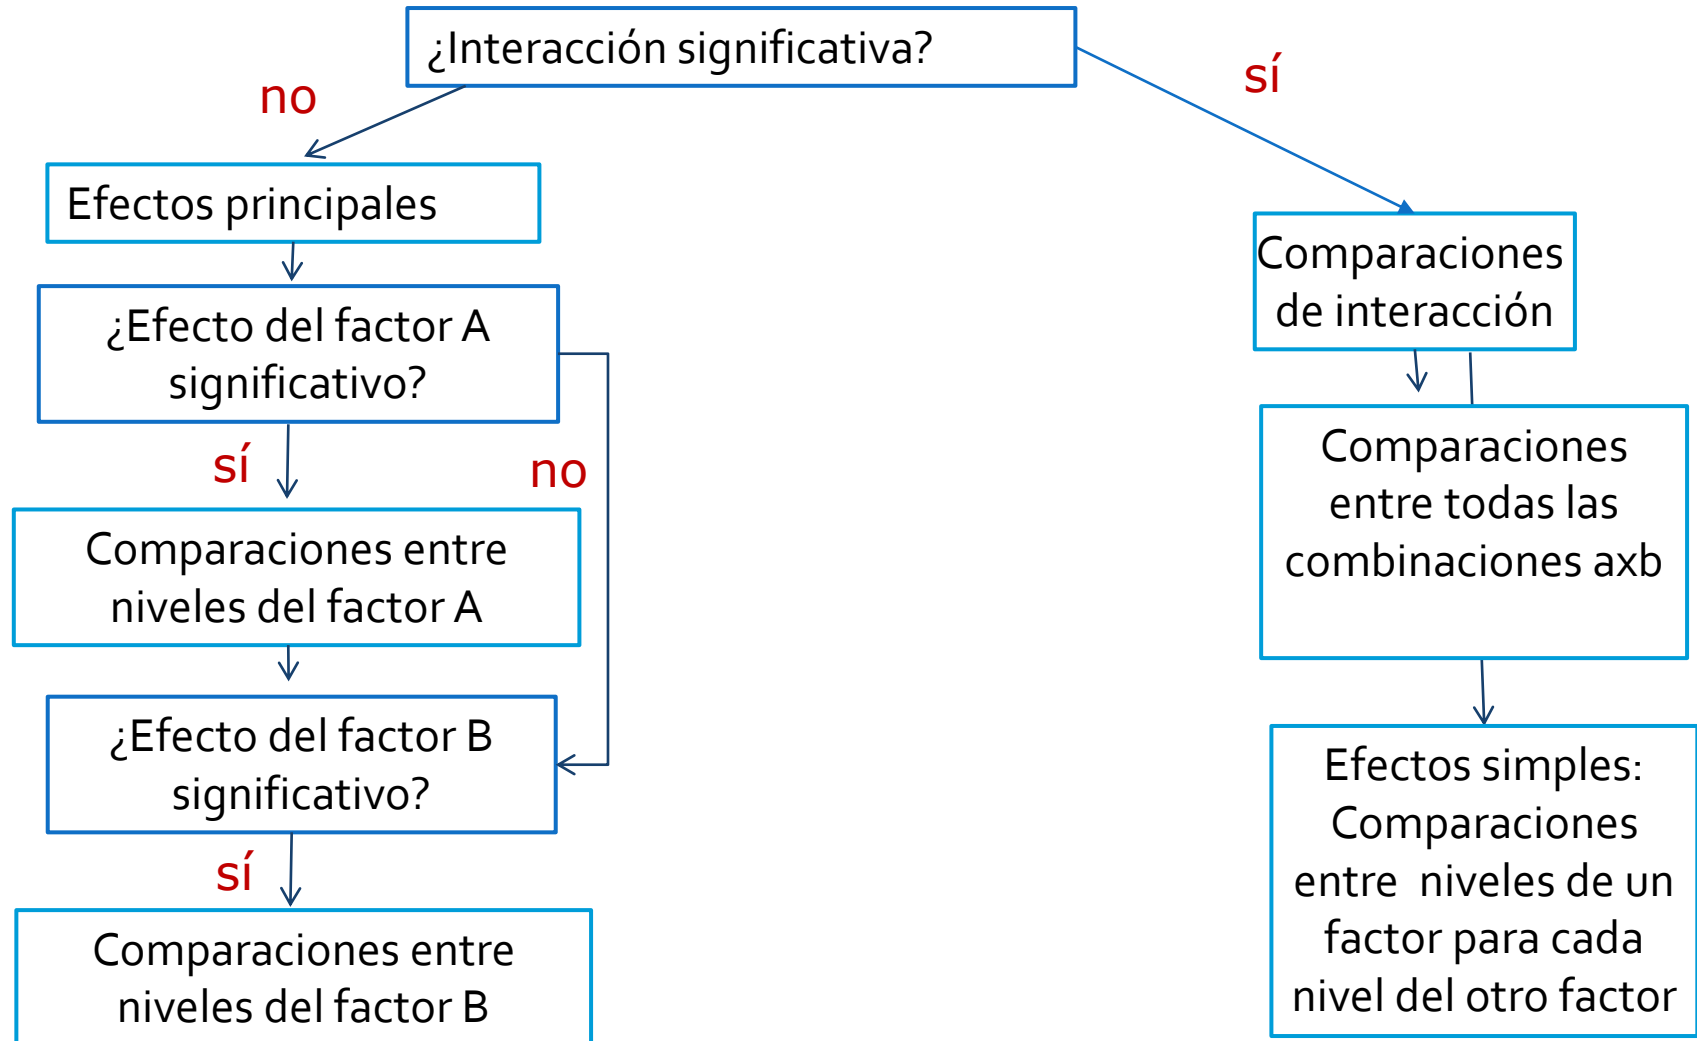
```
emmeans(modelo2, pairwise ~ fert)
```

Comparaciones entre niveles del factor veg

```
emmeans(modelo2, pairwise ~ veg)
```

# Análisis en diseños factoriales

45



# Diseños más complejos

24

- Si se tienen 3 VE (A, B, C) hay una interacción triple y 3 dobles, además de los efectos principales (A, B, C, A\*B, A\*C, B\*C, A\*B\*C)
- El modelo debe respetar el principio de marginalidad: si se incluye una interacción, se deben incluir los efectos principales de las VE que la constituyen

Fuente de variación	Escenario 1	Escenario 2	Escenario 3	Escenario 4
A				
B				
C				
A*B		S	S	NS
A*C		S	NS	NS
B*C		S	NS	NS
A*B*C	S	NS	NS	NS

Ej de efectos simples en escenario 1 y 2:

```
emmeans(m1, pairwise~ A*B|C, adjust= "tukey")
```



# Selección de modelos con más de una v.explicatoria

25

- Experimentos diseñados:
  - ▣ Las VE son en general cualitativas (factores)
  - ▣ el modelo viene dado por el diseño experimental, no se lo debería simplificar
  - ▣ VE generalmente ortogonales
- Estudios observacionales:
  - ▣ VE cuanti y/o cualitativas (regresión múltiple)
  - ▣ es necesario simplificar el modelo => métodos de selección de modelos
  - ▣ VE casi nunca ortogonales

VE ortogonales: La variabilidad explicada por un factor es la misma, independientemente de si el otro factor es tenido en cuenta o no. Verdadera partición de la variabilidad

# Diseños desbalanceados

26

- Cuando los diseños factoriales están **desbalanceados** (distinta cantidad de réplicas en las combinaciones) las SC dejan de ser ortogonales y los resultados pueden diferir según cómo se calculen
- La pérdida de ortogonalidad puede darse también por asociación entre las VE (infrecuente en experimentos pero muy frecuente en estudios observacionales)
- Existen distintos métodos para calcularlas (tipo I, tipo III), que difieren en cómo se calculan las medias marginales

- Simulo desbalanceo en el diseño

```
FITOR[sample(1:nrow(FITOR), 20,  
replace=FALSE),]
```

- Calculo SC tipo I y tipo III

```
> anova(modelo3) #solo tipo I  
Analysis of Variance Table
```

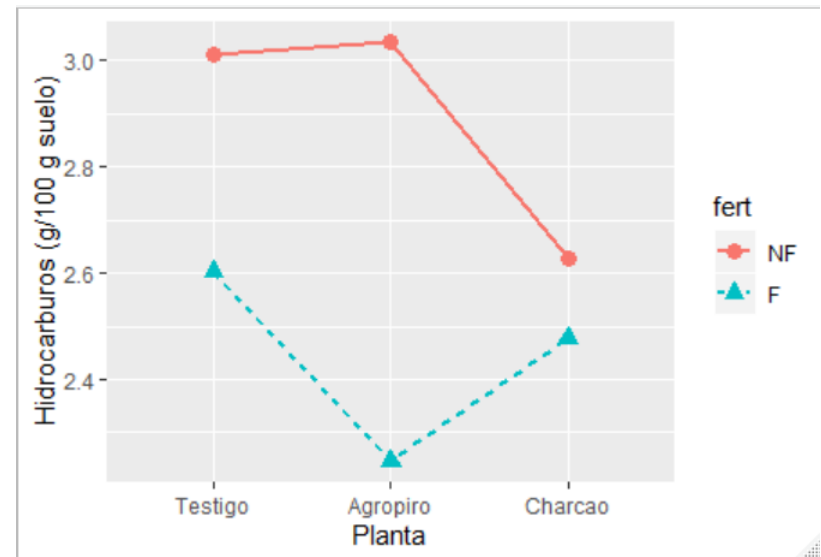
Response: HC

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
veg	2	1603.5	801.8	1.8792	0.1893
fert	1	13041.8	13041.8	30.5677	7.431e-05 ***
veg:fert	2	3297.3	1648.7	3.8642	0.0461 *
Residuals	14	5973.1	426.7		

```
> Anova(modelo3, type="III") #paquete car  
Anova Table (Type III tests)
```

Response: HC

	Sum Sq	Df	F value	Pr(>F)
(Intercept)	154587	1	362.3254	2.1e-11 ***
veg	980	2	1.1487	0.3451918
fert	11109	1	26.0376	0.0001609 ***
veg:fert	3297	2	3.8642	0.0461000 *
Residuals	5973	14		



fert	veg	HC
F	Agropiro	3
NF	Agropiro	4
F	Charcao	2
NF	Charcao	5
F	Testigo	3
NF	Testigo	3

# Sumas de cuadrados

28

## □ SC secuenciales o Tipo I

- Particionan la SC del modelo según la secuencia de incorporación de términos => el orden importa
- Miden la contribución de una VE siendo que las VE que **la preceden** en el modelo ya están incluidas en el mismo
- Como pesa las medias marginales por la cantidad de observaciones, el tamaño de las celdas importa
- Es una verdadera partición de la SC total

$$SC_{X_1}$$

$$SC_{X_2/X_1}$$

$$SC_{X_3/X_1, X_2}$$

## □ SC parciales, ajustadas o Tipo III

- Miden la contribución de una VE siendo que **todas las otras** VE ya están incluidas en el modelo => el orden no importa
- se basa en medias marginales sin ponderar (les da el mismo peso independientemente de la cantidad de observaciones)
- No es una verdadera partición de la SC total

$$SC_{X_1/X_2, X_3}$$

$$SC_{X_2/X_1, X_3}$$

$$SC_{X_3/X_1, X_2}$$

# Resumiendo:

29

## Cuando hay ortogonalidad entre las VE:

- La variabilidad explicada por un factor es la misma, independientemente si la otra VE es tenida en cuenta o no
- SC total puede descomponerse en fuentes de variación independientes y aditivas
- SC secuencial = SC parcial o ajustada
- En experimentos diseñados y balanceados, las SC son ortogonales. En regresión múltiple sólo se daría si las VE fueran estrictamente independientes entre sí (correlación nula). Imposible en estudios observacionales...

## Cuando no hay ortogonalidad entre las VE:

- La significación de la interacción es la misma en ambos métodos
- La SC tipo III respeta el principio de marginalidad, más recomendable
- Alternativamente los datos pueden analizarse utilizando un **diseño de celdas** (comparando a x b tratamientos)