

# BIOMETRÍA II

## CLASE 4

### ANALISIS DE LA VARIANZA

### MODELADO DE VARIANZAS

Adriana Pérez  
Depto de Ecología, Genética y Evolución  
FCEN, UBA

# Marcadores biológicos de contaminación ambiental


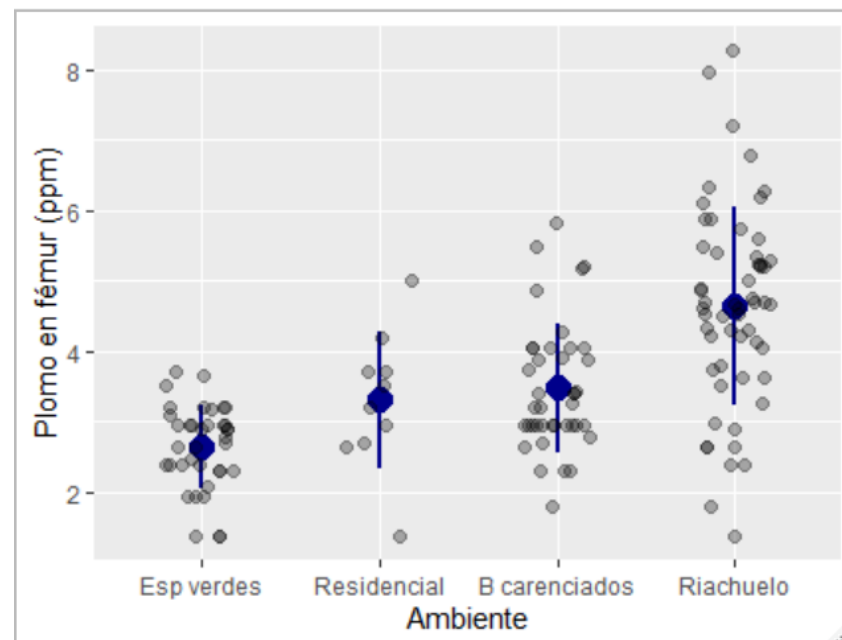
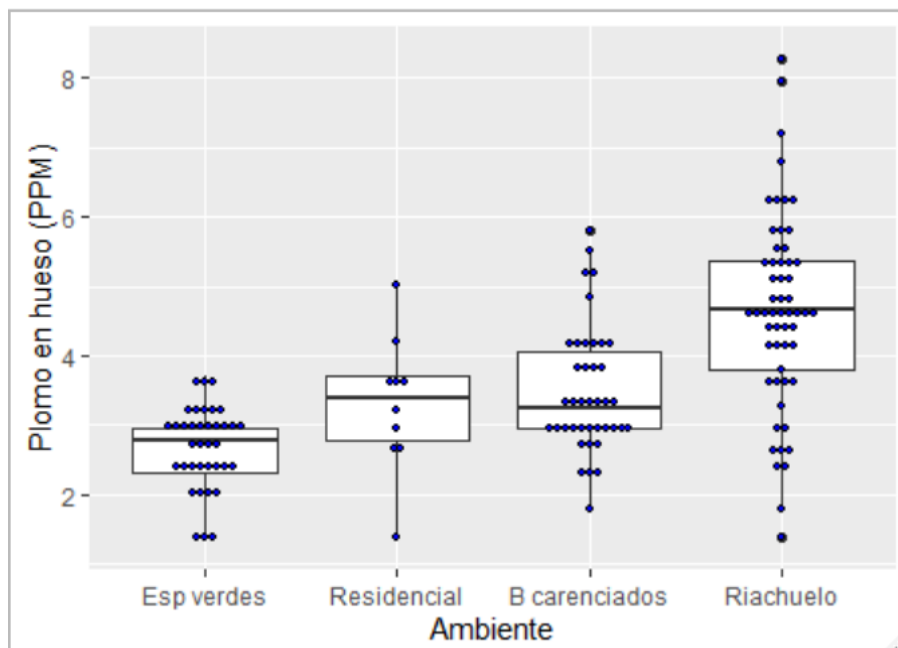


- Las ratas (genero *Rattus*) presentan áreas de actividad relativamente pequeñas, por lo que se ha sugerido que podrían ser usadas para la detección de contaminación ambiental por metales pesados del ambiente en el que viven
- Se desea comparar el nivel de acumulación media de plomo en ratas provenientes de distintos ambientes de CABA
- Para ello se efectuó un muestreo aleatorio de *Rattus norvegicus* en 4 ambientes contrastantes: *Espacios verdes*; *Barrios residenciales*; *Barrios carenciados* y *Costa del Riachuelo*.
- En cada ejemplar se registró el nivel de acumulación de plomo en fémur (ppm) (n=143)
  - Experimento o estudio observacional?
  - Unidad muestral / experimental? Independencia?
  - variable respuesta? Tipo y potencial distribución de probabilidades?
  - variable explicativa? Tipo y niveles?
  - Modelo?

Plomo.txt

	Ambiente	Pb
1	Esp verdes	2.484907
2	Esp verdes	2.944439
3	Esp verdes	2.772589
4	Esp verdes	2.397895
5	Esp verdes	2.890372
6	Esp verdes	2.397895
7	Esp verdes	2.079442
8	Esp verdes	2.890372
9	Esp verdes	2.944439
10	Esp verdes	2.639057
11	Esp verdes	2.639057
12	Esp verdes	1.945910
13	Esp verdes	3.178054

Showing 1 to 13 of 143 entries

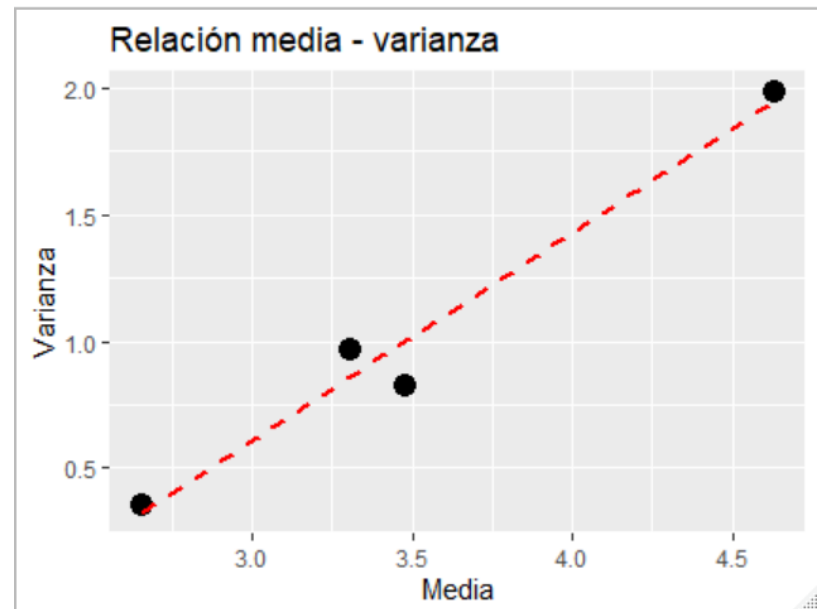


# Estadística descriptiva

Variable respuesta: Pb

VE o factor: Ambiente con 4 niveles


Ambiente	n	media	DE	var	min	max
<fct>	<int>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1 Esp verdes	37	2.65	0.593	0.351	1.39	3.71
2 Residencial	10	3.31	0.984	0.968	1.39	5.02
3 B carenciados	40	3.48	0.910	0.828	1.79	5.81
4 Riachuelo	56	4.63	1.41	1.98	1.39	8.27



# Modelo de comparación de medias

5

$$E(Y_i) = \mu + \alpha_i \quad \varepsilon_{ij} \sim \text{Normal}(0, \sigma^2)$$



```
modelo1<-lm(Pb ~ Ambiente, data=bd)
```

# Supuestos del modelo

(mismos  
supuestos  
menos  
linealidad)



```
> anova(modelo1)  
Analysis of Variance Table
```

Response: Pb

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Ambiente	3	92.348	30.7828	26.308	1.541e-13
Residuals	139	162.643	1.1701		

6

```
> modelo1<-lm(Pb ~ Ambiente, data=bd)
```



```
> leveneTest(modelo1)  
Levene's Test for Homogeneity of Variance  
      Df F value    Pr(>F)  
group  3  5.0704 0.002313 **  
139
```

```
> shapiro.test(residuals(modelo1))
```

shapiro-wilk normality test

data: residuals(modelo1)  
W = 0.97456, p-value = 0.009099

El p-valor obtenido no es confiable

# La buena noticia: podemos modelar la estructura de varianzas

$$\text{var}(\varepsilon_i) = \sigma^2 \cdot \textit{función de varianza}$$

$$\text{var}(\varepsilon_i) = \sigma^2 \cdot f(\mu_i, X, \delta)$$

Se incorpora al modelo una función de varianza que puede depender de:

- $\mu_i$  = media o esperanza de la variable respuesta
- $X$  = **covariable** para la varianza. Cualquier variable utilizada para modelar la estructura de varianzas de los errores
- $\delta$  = parámetro; es estimado en función de la estructura de varianzas propuesta

Las estimaciones son por mínimos cuadrados generalizados

# Funciones de varianza

Identidad (`varIdent`): una varianza distinta para cada grupo

$$\varepsilon_i \sim N(0, \sigma^2_i)$$

Exponencial (`varExp`): la varianza como función exponencial de alguna covariable

$$\varepsilon_i \sim N(0, \sigma^2 \cdot e^{2\delta \cdot X_i})$$

Potencia (`varPower`): la varianza como función de potencia de alguna covariable

$$\varepsilon_i \sim N(0, \sigma^2 \cdot |X_i|^{2\delta})$$

Fija (`varFixed`): la varianza como función lineal de alguna covariable

$$\varepsilon_i \sim N(0, \sigma^2 \cdot X_i)$$

```
library("nlme")  
gls(Y ~ X, weights="XX", data)
```

```
varIdent(form=~1|A)  
varPower()  
varExp()  
varFixed(~X)
```



# ¿Cuál función utilizar?

## varIdent

- Es la única que admite variables **cualitativas** como covariable
- Estima diferentes varianzas para cada nivel de la covariable ( $\sigma^2_i$ ). Se estiman tantas varianzas como niveles -1

## varPower

- No se puede usar cuando la covariable toma valores iguales a 0
- Requiere estimar un parámetro ( $\delta$ )

## varConstantPower

- Simil varPower pero se le suma una constante a la covariable:
- Requiere estimar dos parámetros ( $\delta$  y la cte)
- Para covariables que toman valores iguales a 0

## varExp

- Se puede usar cuando la covariable toma valores iguales a 0
- Puede tener problemas de estimación cuando los valores de la covariable son altos (i.e.  $> 100$ ); en esos casos conviene reescalar
- Requiere estimar un parámetro ( $\delta$ )




## varFixed

- No requiere estimar ningún parámetro

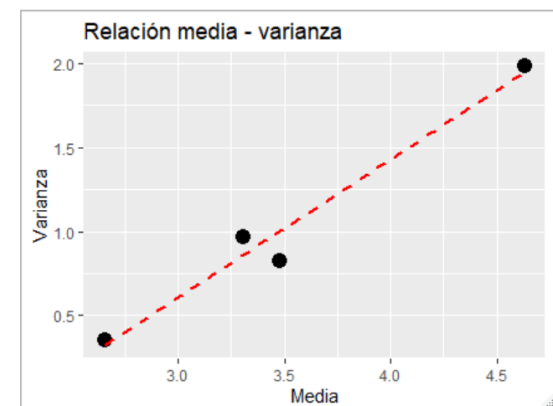
Explorar la relación  
varianza-media

# Relación entre esperanza y varianza

10



Crawley 2007



# Cuadrados mínimos generalizados (glS)

## Modelando varianzas: varIdent(Ambiente)

11

```
> #modelo 3 modelado varianzas. varIdent(ambiente)
> modelo3<-glS(Pb~Ambiente, weights=varIdent(form=~1|Ambiente), data=Plomo)
> anova(modelo3)
```

Denom. DF: 139

	numDF	F-value	p-value
(Intercept)	1	1951.0503	<.0001
Ambiente	3	30.9453	<.0001

```
> modelo3
```

Generalized least squares fit by REML

Estimación por MV  
restringida (por default)

Model: Pb ~ Ambiente

Data: Plomo

Log-restricted-likelihood: -200.2043

Coefficients:

(Intercept)	AmbienteEsp verdes	AmbienteResidencial	AmbienteRiachuelo
3.4763281	-0.8221418	-0.1706125	1.1526315

Variance function:

Structure: Different standard deviations per stratum

Formula: ~1 | Ambiente

Parameter estimates:

Esp verdes	B carenciados	Residencial	Riachuelo
1.000000	1.534740	1.659941	2.374431

Degrees of freedom: 143 total; 139 residual

Residual standard error: 0.5928515

D.E. de Riachuelo/D.E. Esp verdes

Desvío estándar de Esp verdes

# Cuadrados mínimos generalizados (gls)

## Modelando varianzas: varIdent(Ambiente)

12

```
modelo3<-gls(Pb~Ambiente, weights=varIdent(form=~1|Ambiente), method="ML", data=bd)
```

```
> modelo3
```

```
Generalized least squares fit by maximum likelihood
```

Estimación por MV

```
Model: Pb ~ Ambiente
```

```
Data: bd
```

```
Log-likelihood: -196.7303
```

```
Coefficients:
```

```
(Intercept)  
2.6541863
```

```
AmbienteResidencial  
0.6515293
```

```
AmbienteB carenciados  
0.8221418
```

```
AmbienteRiachuelo  
1.9747733
```

```
Variance function:
```

```
Structure: Different standard deviations per stratum
```

```
Formula: ~1 | Ambiente
```

```
Parameter estimates:
```

```
Esp verdes B carenciados Residencial Riachuelo  
1.000000 1.536338 1.596478 2.385593
```

```
Degrees of freedom: 143 total; 139 residual
```

```
Residual standard error: 0.5847852
```

Cambian las  
estimaciones!

Cuando  $n$  es grande los estimadores de varianza por MV son normalmente asintóticos y consistentes. Cuando  $n$  es chico la estimación es **sesgada** ya que no divide por los GL sino por  $n$ . Eso se corrige empleando MV restringida (REML) que genera una función de verosimilitud sin considerar los efectos fijos

# Modelando varianzas: varIdent(Ambiente)

## Análisis de residuos (modelo3)


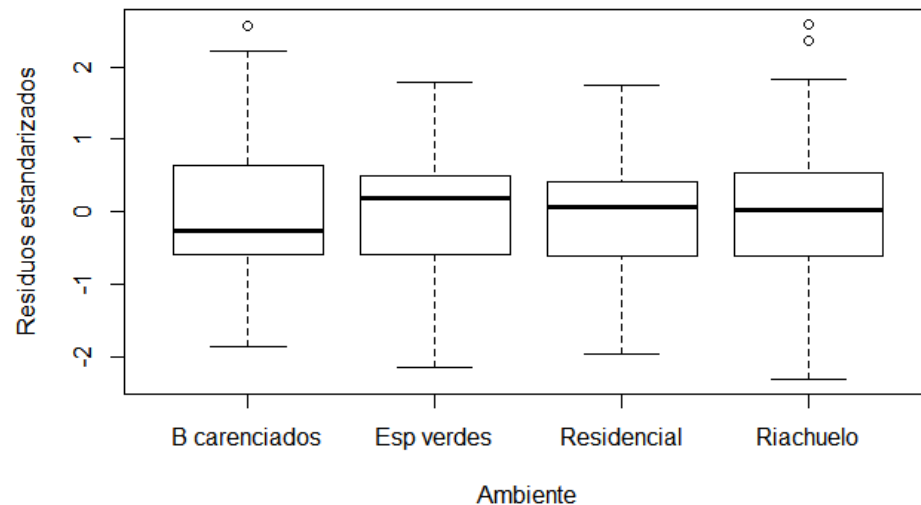



Gráfico de dispersión de RE vs PRED



$$RE_i = \frac{y_i - \hat{y}_i}{\sqrt{\hat{\sigma}_i^2}}$$

O la función de  
varianza que  
corresponda

# Cuadros mínimos generalizados (gls)

## Modelando varianzas: varPower

14

```
modelo4<-gls(Pb~Ambiente, weights=varPower(), data=Plomo)
```

```
> anova(modelo4)
```

```
Denom. DF: 139
```

	numDF	F-value	p-value
(Intercept)	1	1940.6731	<.0001
Ambiente	3	30.1536	<.0001

```
> modelo4
```

```
Generalized least squares fit by REML
```

```
Model: Pb ~ Ambiente
```

```
Data: Plomo
```

```
Log-restricted-likelihood: -200.4478
```

```
Coefficients:
```

(Intercept)	AmbienteEsp verdes	AmbienteResidencial	AmbienteRiachuelo
3.4763281	-0.8221418	-0.1706125	1.1526315

```
Combination of variance functions:
```

```
Structure: Power of variance covariate
```

```
Formula: ~fitted(.)
```

```
Parameter estimates:
```

```
power  
1.529801
```

$\hat{\sigma}$

```
Degrees of freedom: 143 total; 139 residual
```

```
Residual standard error: 0.1362282
```

$\hat{\sigma}$

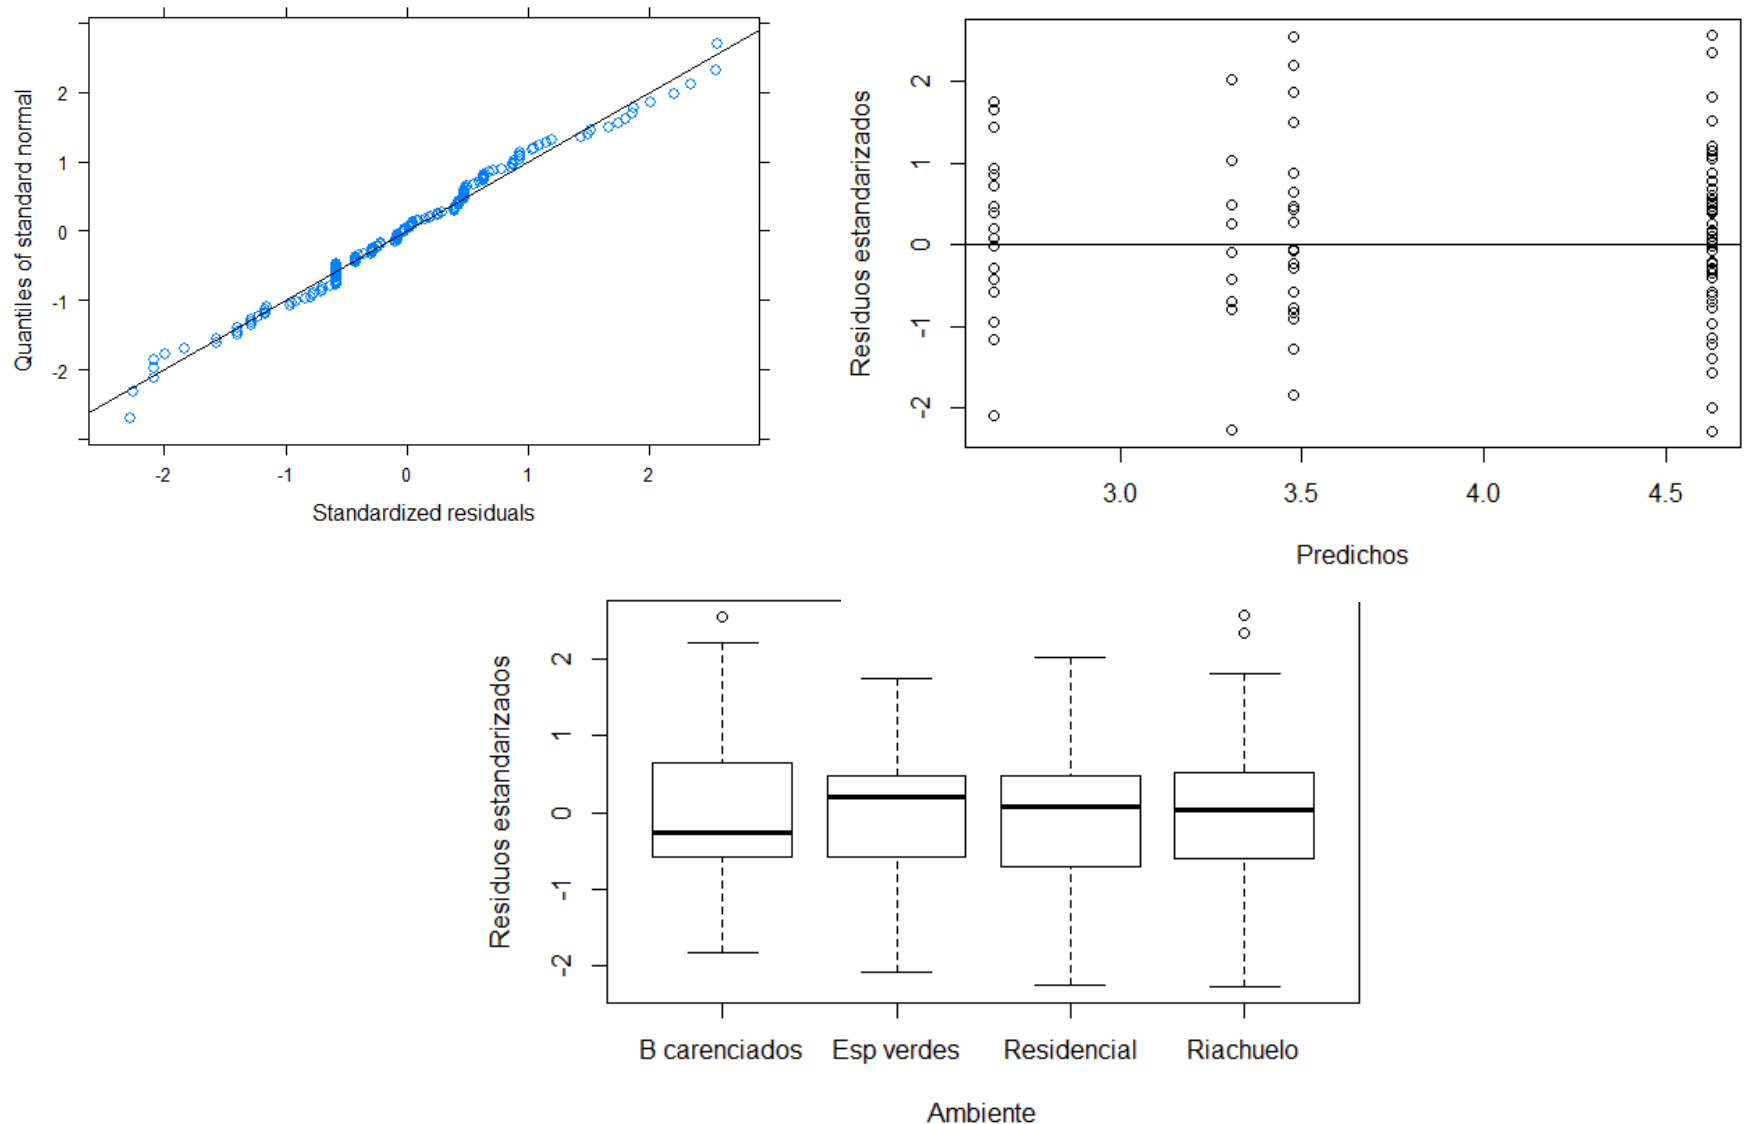
$$RE_i = \frac{y_i - \hat{y}_i}{\sqrt{\hat{\sigma}^2 * |X_i|^{2*\hat{\sigma}}}}$$

$$RE_i = \frac{y_i - \hat{y}_i}{\sqrt{0,136^2 * |\hat{y}_i|^{2*1,53}}}$$

# Modelando varianzas: VarPower

## Análisis de residuos (modelo<sub>4</sub>)

Gráfico de dispersión de RE vs PRED



# Varios modelos posibles

16

	Residuos
Modelo 2: gls sin modelar varianzas. Se descarta por los residuos	<b>x</b>
Modelo 3: gls modelando varianzas por varIdent(ambiente)	<b>ok</b>
Modelo 4: gls modelando varianzas por varPower	<b>ok</b>
Modelo 5: gls modelando varianzas por varExp	<b>ok</b>

¿Cuál elegir?



# Selección de modelos

17

## Criterios de información:

- Resumen la información de un modelo, teniendo en cuenta la función de verosimilitud  $L(\theta)$  (cuanto mayor, mejor) y el número de parámetros a estimar del modelo ( $p$ ) (cuanto mayor, peor)
- Estiman la distancia relativa entre el modelo ajustado y el mecanismo verdadero pero desconocido (de tal vez infinitos parámetros) que generó los datos observados
- El valor individual no es interpretable, solo sirve con fines comparativos: **cuanto menor, mejor el modelo**

# Comparación de modelos

18

## Criterios de información:

- Akaike (AIC)
- Bayesiano de Schwartz (BIC)

$$AIC = -2\log L(\theta) + 2p$$

$$BIC = -2\log L(\theta) + p \ln(n)$$



Medida del  
ajuste

Penalización  
por la  
complejidad  
del modelo

- AIC y BIC menores, implican mejor ajuste

L	Log(L)	-2xLog(L)
0	--	--
0.1	-1	2
0.2	-0.70	1.40
0.3	-0.52	1.05
0.4	-0.40	0.80
0.5	-0.30	0.60
0.6	-0.22	0.44
0.7	-0.15	0.31
0.8	-0.10	0.19
0.9	-0.05	0.09
1	0	0

- BIC penaliza más que AIC los modelos con más parámetros a estimar

Burnham, K. P., Anderson, D. R., & Huyvaert, K. P. (2011). AIC model selection and multimodel inference in behavioral ecology: some background, observations, and comparisons. *Behavioral ecology and sociobiology*, 65(1), 23-35.

# Varios modelos

19

Modelo 2: gls sin modelar varianzas. Se descarta por los residuos

Modelo 3: gls modelando varianzas por varIdent(ambiente)

Modelo 4: gls modelando varianzas por varPower

Modelo 5: gls modelando varianzas por varExp

```
> AIC(modelo2,modelo3,modelo4,modelo5)
```

	df	AIC
--	----	-----

modelo3	8	416.4087
---------	---	----------

modelo4	6	412.8956
---------	---	----------

modelo5	6	413.3685
---------	---	----------

- 1- Seleccionamos los modelo con residuos adecuados (modelos 3 a 5)
- 2- Seleccionamos el que presente menor AIC (modelo 4)

# Anova

$$E(Y_i) = \mu + \alpha_i$$

H1: Algún  $\alpha_i \neq 0$

20

```
modelo4<-gls(Pb~Ambiente, weights=varPower(), data=Plomo)
```

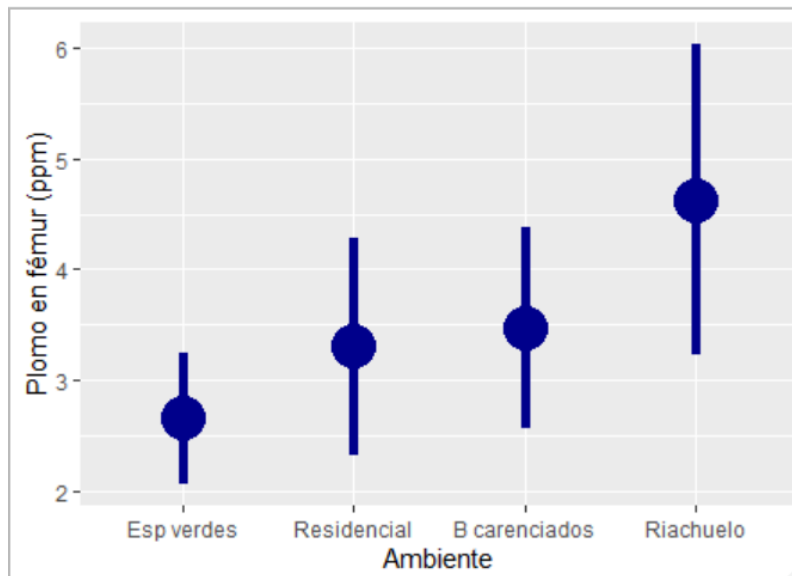
```
> anova(modelo4)
```

```
Denom. DF: 139
```

	numDF	F-value	p-value
(Intercept)	1	1940.6731	<.0001
Ambiente	3	30.1536	<.0001

P-valor < 0,05

La concentración media de plomo en los fémures de las ratas de **alguno** de los ambientes difiere significativamente de la media general



Comparaciones múltiples

# Anova

## Comparaciones múltiples

21

- Sirven para detectar diferencias entre las medias de los tratamientos como complemento a la prueba global
- Controlan de alguna manera el error global, es decir la probabilidad de cometer al menos un error tipo I.
- Equivalen a hacer múltiples test t con algún tipo de ajuste
- Existen distintos métodos de comparación, según como controlen el error global

# Comparaciones múltiples

22

- Compara subgrupos de medias. Por ejemplo de a pares:
  - ▣  $H_0: \mu_i = \mu_j$  (o lo que es lo mismo,  $\mu_i - \mu_j = 0$ )
  - ▣  $H_1: \mu_i \neq \mu_j$  (o lo que es lo mismo,  $\mu_i - \mu_j \neq 0$ )
- La lógica es la del test de t para la comparación de dos medias. Los distintos métodos difieren en cómo se calcula el EE, en la distribución de probabilidades, en ajustes en nivel de significación, etc

$$t_{GL} = \frac{\Delta \bar{Y} - \Delta \mu}{EE_{\bar{Y}_1 - \bar{Y}_2}} = \frac{\Delta \bar{Y} - \Delta \mu}{\sqrt{\frac{S^2}{n_1} + \frac{S^2}{n_2}}} = \frac{\Delta \bar{Y} - \Delta \mu}{\sqrt{\frac{CMerror}{n_1} + \frac{CMerror}{n_2}}}$$

EE para la diferencia de medias

$$\Delta \bar{Y} \pm P_{GL, \alpha} EE_{\Delta \bar{Y}}$$

Se puede expresar como un IC para la diferencia de dos medias y ver si cero pertenece al IC. Además permite estimar la magnitud del efecto

# Clasificación de los métodos

23

## A priori: planeados

- ▣ Las hipótesis se plantean antes del muestreo
- ▣ Se basan en información independiente del experimento
- ▣ pueden detectar diferencias aunque el anova no lo haya hecho, ya que incorporan información que ni la hipótesis global ni las comparaciones a posteriori poseen
- ▣ Mayor sensibilidad, mayor potencia
  - Contrastes ortogonales
  - Método de Bonferroni
  - Método de Dunnet

## A posteriori: no planeados

- ▣ se aplican sólo si el Anova dio significativo
- ▣ “búsqueda de significación”, exploratorios
- ▣ Más conservativos, menos potentes
  - Método de Tukey

# Comparaciones no planeadas

## Método de Tukey



24

- Compara todos los pares posibles de medias
- La cantidad total de comparaciones de a pares posibles con  $a$  grupos es:

$$\frac{a(a-1)}{2}$$

$$q_{GL\ dentro,a} = \frac{\Delta \bar{Y} - \Delta \mu}{\sqrt{\frac{CM_{error}}{n_i}}}$$

Distribución de TUKEY

- Procedimiento: Se calculan todas las diferencias entre las medias de los tratamientos y se comparan con una diferencia crítica o **diferencia mínima significativa** (DMS):

$$\Delta \bar{Y} \text{ vs } DMS = q_{GL\ dentro,\alpha,k} \sqrt{\frac{CM_{dentro}}{n_i}}$$

- Alternativamente se calcula un IC para la diferencia de dos medias



Usando paquete emmeans. Tukey por default  
`emmeans(modelo4, pairwise ~ Ambiente)`

```
$emmeans
```

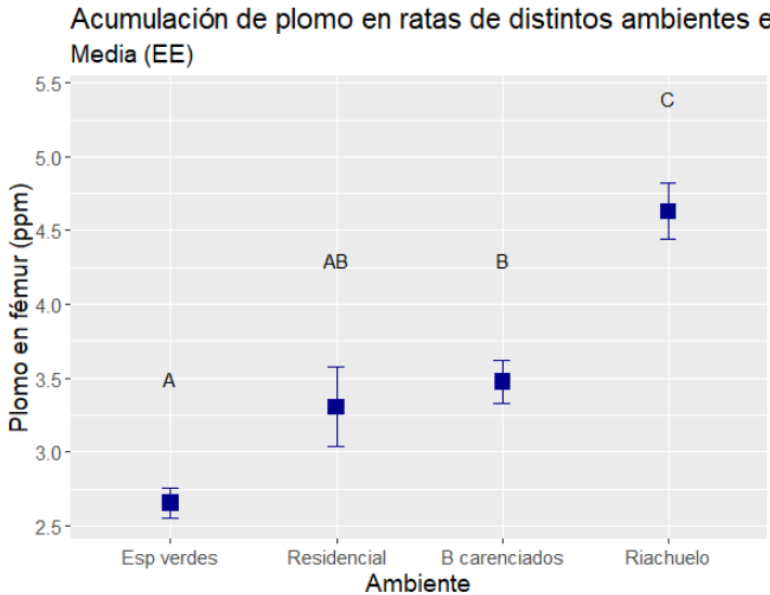
Ambiente	emmean	SE	df	lower.CL	upper.CL
Esp verdes	2.65	0.0993	43.1	2.45	2.85
Residencial	3.31	0.2680	109.3	2.77	3.84
B carenciados	3.48	0.1448	128.7	3.19	3.76
Riachuelo	4.63	0.1904	76.8	4.25	5.01

d.f. method: satterthwaite  
 Confidence level used: 0.95

```
$contrasts
```

contrast	estimate	SE	df	t.ratio	p.value
Esp verdes - Residencial	-0.652	0.286	98.5	-2.280	0.1098
Esp verdes - B carenciados	-0.822	0.176	94.7	-4.683	0.0001
Esp verdes - Riachuelo	-1.975	0.215	122.9	-9.196	<.0001
Residencial - B carenciados	-0.171	0.305	113.9	-0.560	0.9436
Residencial - Riachuelo	-1.323	0.329	142.5	-4.025	0.0005
B carenciados - Riachuelo	-1.153	0.239	117.5	-4.818	<.0001

P value adjustment: tukey method for comparing a family of 4 estimates



¿Las medias difieren significativamente?  
 ¿En qué magnitud?

Graficar siempre las estimaciones que surgen del modelo

No usar los IC para la media para determinar si hay diferencias.  
 Lo correcto es analizar IC para la diferencia de medias

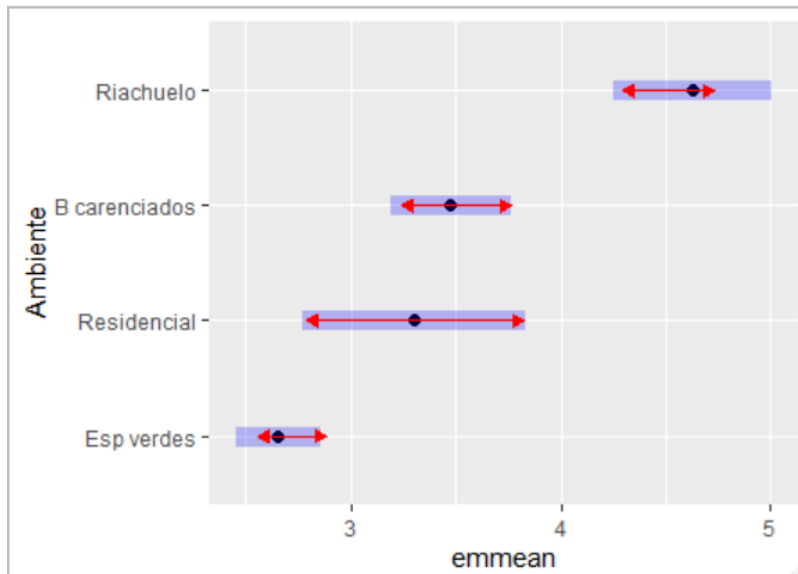
\$contrasts

contrast	estimate	SE	df	lower.CL	upper.CL
Esp verdes - Residencial	-0.652	0.286	98.5	-1.398	0.0953
Esp verdes - B carenciados	-0.822	0.176	94.7	-1.281	-0.3630
Esp verdes - Riachuelo	-1.975	0.215	122.9	-2.534	-1.4155
Residencial - B carenciados	-0.171	0.305	113.9	-0.965	0.6236
Residencial - Riachuelo	-1.323	0.329	142.5	-2.178	-0.4686
B carenciados - Riachuelo	-1.153	0.239	117.5	-1.776	-0.5291

IC95% para la diferencia de medias:

Contiene al cero? Si lo contiene, cuál es su magnitud?

Las barras azules son IC para la media. Las flechas rojas indican comparaciones entre medias. Si las flechas de dos grupos se solapan, las diferencias no son estadísticamente significativas



Con una confianza del 95% se estima que la concentración de plomo en fémur de ratas de Riachuelo es, en promedio, entre 1,43 y 2,52 ppm mayor a la de ratas de espacios verdes

# Método de Bonferroni

27

- Consiste en ajustar los valores p de las pruebas de hipótesis individuales de manera de controlar el error global (**corrección por múltiples tests**)

$$\text{valor } p \text{ corregido} = \text{valor } p \cdot m$$

- O lo que es lo mismo,  $\alpha \text{ corregido} = \alpha^* = \frac{\alpha}{m}$   
donde  $m$  es la cantidad de comparaciones que se efectúan
- Si solo se hace una comparación, equivale a un test t. Pero la prueba va perdiendo potencia si  $m$  es muy grande
- Existen variantes no tan conservadoras **Bonferroni secuencial (Holm, 1979)**

```
$contrasts
contrast      estimate    SE    df t.ratio p.value
Esp verdes - Residencial    -0.652 0.286  98.5 -2.280  0.1486
Esp verdes - B carenciados  -0.822 0.176  94.7 -4.683  0.0001
Esp verdes - Riachuelo     -1.975 0.215 122.9 -9.196 <.0001
Residencial - B carenciados -0.171 0.305 113.9 -0.560  1.0000
Residencial - Riachuelo     -1.323 0.329 142.5 -4.025  0.0006
B carenciados - Riachuelo   -1.153 0.239 117.5 -4.818 <.0001
```

P value adjustment: bonferroni method for 6 tests



# Contrastes ortogonales

28

- Otra lógica: preguntas específicas planteadas a priori basadas en información por fuera del ensayo (pocas, bien dirigidas, máxima potencia)
- Los contrastes deben ser independientes (ortogonales) entre sí, ya que consisten en una descomposición de la SC de los tratamientos
- Como máximo  $\# \text{grupos} - 1$  contrastes
- Solo para diseños balanceados
- Equivale a un test t

# Contrastes ortogonales

29

- Máximo 3 contrastes
- ¿Zonas con mayor cobertura vegetal (espacios verdes y residenciales) difieren de zonas con menor cobertura (barrios carenciados y Riachuelo)?
- ¿espacios verdes y residenciales difieren entre sí?

$$Ho^1 : \frac{\mu_{esp.verd} + \mu_{res}}{2} = \frac{\mu_{b.car} + \mu_{riach}}{2} \Rightarrow \frac{\mu_{esp.verd} + \mu_{res}}{2} - \frac{\mu_{b.car} + \mu_{riach}}{2} = 0$$

$$Ho^2 : \mu_{esp.verd} = \mu_{res} \Rightarrow \mu_{esp.verd} - \mu_{res} = 0$$

Contraste	1	2	ci cj
Esp verdes			
Residenciales			
Carenciados			
Riachuelo			

$$\sum c_i = 0$$

$$\sum c_i c_j = 0 \text{ para todos } (i, j)$$

# Contrastes ortogonales

30

1. Creamos la matriz de coeficientes

```
c1<-c(1/2,1/2, -1/2,-1/2)
c2<-c(1,-1,0,0)
matriz_contrastes<-cbind(c1,c2)
```

```
> matriz_contrastes
```

```
      c1 c2
[1,] 0.5  1
[2,] 0.5 -1
[3,] -0.5  0
[4,] -0.5  0
```

2. Ajustamos el modelo

```
modelo4b <- lm(Pb ~ Ambiente, data=bd, contrasts =
list(dosis_cd_cuali=matriz_contrastes))
summary(modelo4b)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
(Intercept)	3.5643	0.1208	29.516	< 2e-16	***
Ambientec1	-1.1687	0.2415	-4.839	3.4e-06	***
Ambientec2	-0.3258	0.2096	-1.554	0.122	

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1



# ¿Cuál método de comparación elegir?

31

**Tukey:** todos contra todos, de a pares. “Búsqueda de significación”, exploratorio. El más recomendable para ese objetivo

**Bonferroni:** Cuantas más comparaciones menos potente

**Dunnet:** todos contra el control

**Ortogonal:** el más potente de todos, pero con serias restricciones acerca de las comparaciones que se pueden efectuar (deben ser matemáticamente ortogonales)

⇒ Compromiso entre cantidad de preguntas que se desean responder y potencia (a fin de mantener el error global)

# Modelo4 como regresión lineal

	value
AmbienteEsp verdes	2.654186
AmbienteResidencial	3.305716
AmbienteB carenciados	3.476328
AmbienteRiachuelo	4.628960

32

```
modelo4<-glS(Pb~Ambiente, weights=varPower(), data=Plomo)
```

```
> summary(modelo4)
```

Generalized least squares fit by REML

Variance function:

Structure: Power of variance covariate

Formula: ~fitted(.)

Parameter estimates:

power

1.529801

Coefficients:

	value	Std.Error	t-value	p-value
(Intercept)	2.6541863	0.09970036	26.621633	0.0000
AmbienteResidencial	0.6515293	0.28623657	2.276192	0.0244
AmbienteB carenciados	0.8221418	0.17588010	4.674445	0.0000
AmbienteRiachuelo	1.9747733	0.21436703	9.212113	0.0000

Magnitud del efecto  
(diferencia de medias)

EE para la  
diferencia de  
medias

- ❑ Salvo cuando hay solo dos niveles, no hay una prueba “global” sobre el efecto de la VE
- ❑ Los coeficientes son diferencias de medias con respecto al nivel de referencia; no se informan otras comparaciones
- ❑ No son comparaciones ortogonales
- ❑ No controlan el error global



# Resumiendo

33

- El análisis de la varianza puede usarse para comparar cualquier cantidad de grupos con respecto a su media
- Si la VE es cuantitativa y afecta a la VR según una función modelable, es más eficiente utilizar regresión que anova (más parsimoniosa, permite interpolar)
- Si la VE es cuali o si es cuanti pero sin una relación clara, se recomienda Anova
- Luego del ANOVA se debe aplicar algún método de comparaciones entre grupos. La elección del método depende de los objetivos
- Para leer sobre IC en comparaciones: Cumming, G., & Finch, S. (2005). Inference by eye: confidence intervals and how to read pictures of data. *American Psychologist*, 60(2), 170.